



UNIVERSITÀ
DEGLI STUDI
FIRENZE

UNIVERSITÀ DEGLI STUDI DI FIRENZE
DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

Laboratorio di Optimization Methods

Autore:
Niccolò Scommegna

Corso principale:
Optimization Methods

N° Matricola:
7162797

Docente corso:
Matteo Lapucci

19 novembre 2025

Indice

1	Introduzione	2
2	Nozioni Teoriche	2
3	Esperimenti	4
3.1	Numero di Iterazioni	4
3.2	Andamento Funzione Obiettivo e Norme del Gradiente	6
3.3	Tempi di Esecuzione	6

1 Introduzione

In questo report vengono presentati i risultati ottenuti durante lo svolgimento del laboratorio di *Optimization Methods*, che ha avuto come obiettivo l'implementazione dell'algoritmo proposto nell'articolo *A Noise-Tolerant Quasi-Newton Algorithm for Unconstrained Optimization* [1] e il suo confronto con altri algoritmi di ottimizzazione non vincolata, come l'algoritmo di discesa del gradiente e l'algoritmo BFGS. L'implementazione è stata effettuata in linguaggio `Python` e i problemi di ottimizzazione sono stati selezionati dalla libreria `PyCUTEst`.

2 Nozioni Teoriche

Gli algoritmi per l'ottimizzazione non vincolata mirano a trovare il minimo di una funzione obiettivo $f : \mathbb{R}^n \rightarrow \mathbb{R}$ utilizzando informazioni sulla funzione stessa, come il gradiente e la matrice Hessiana. In questa sezione vengono descritte le nozioni teoriche fondamentali alla base degli algoritmi implementati nel progetto, in particolare l'algoritmo di discesa del gradiente, l'algoritmo BFGS e l'algoritmo Quasi-Newton tollerante al rumore proposto da Shi et al. [1]. Il metodo di discesa del gradiente utilizza come direzione di discesa l'antigradiente della funzione obiettivo $-\nabla f(x_k)$ e richiede la scelta di uno scalare α_k per determinare la lunghezza del passo. Una pratica comune è la ricerca di α_k tramite line search, che può essere eseguita utilizzando condizioni di Armijo o Wolfe. Queste condizioni garantiscono che il passo scelto riduca sufficientemente il valore della funzione obiettivo e che la variazione del gradiente lungo la direzione di discesa sia compatibile con la curvatura locale della funzione. In notazione tipica, la condizione di Armijo si scrive come:

$$f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^T d_k, \quad (1)$$

dove $c_1 \in (0, 1)$ è una costante predefinita e d_k è la direzione di discesa. Per quanto riguarda le condizioni di Wolfe, esse includono sia la condizione di Armijo che una condizione di curvatura. Nel complesso le condizioni forti di Wolfe si esprimono come:

$$f(x_k + \alpha_k d_k) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^T d_k, \quad (2)$$

$$|\nabla f(x_k + \alpha_k d_k)^T d_k| \leq c_2 |\nabla f(x_k)^T d_k|, \quad (3)$$

dove $c_2 \in (c_1, 1)$ è un'altra costante predefinita.

L'algoritmo BFGS è un metodo Quasi-Newton che costruisce un'approssimazione della matrice Hessiana B_k basata sui gradienti calcolati nei punti precedenti e la differenza tra i punti delle iterazioni. La matrice B_k viene aggiornata ad ogni iterazione utilizzando la formula di aggiornamento di BFGS:

$$B_{k+1} = B_k + \frac{y_k y_k^T}{s_k^T y_k} - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k}, \quad (4)$$

dove $s_k = x_{k+1} - x_k$ e $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$. Perché l'aggiornamento sia ben definito, e soprattutto per garantire che B_{k+1} sia definita positiva, è necessario e sufficiente che $s_k^T y_k > 0$. Le condizioni di Wolfe forti sono tipicamente impiegate

per assicurare questa proprietà e quindi preservare la definita positività della matrice approssimata della Hessiana ad ogni iterazione. Senza una corretta scelta del passo, che soddisfi tali condizioni, l'aggiornamento potrebbe degenerare e la matrice approssimata potrebbe diventare mal condizionata.

Nell'articolo di Shi et al. [1], si osserva che in presenza di errori (rumore) nella valutazione della funzione e del gradiente, il classico schema BFGS può fallire: differenze di gradiente y_k calcolate su passi troppo piccoli possono essere dominate dal rumore e corrompere l'aggiornamento. Per mitigare questo problema, gli autori propongono modifiche pratiche all'algoritmo BFGS. Gli elementi chiave dell'algoritmo BFGS tollerante al rumore sono:

- **Condizione di controllo del rumore e lengthening:** oltre ad usare le condizioni di Wolfe forti (2, 3) per determinare il passo α_k , viene introdotto il parametro di lengthening (allungamento) $\beta_k \geq \alpha_k$ e richiedono la noise control condition:

$$(\nabla f(x_k + \beta_k d_k) - \nabla f(x_k))^T d_k \geq 2(1 + c_3)\epsilon_g \|d_k\|, \quad (5)$$

dove $c_3 > 0$ è una costante predefinita e ϵ_g è una stima superiore del rumore sul gradiente. Questa condizione garantisce che la differenza osservata nei gradienti sia sufficientemente grande rispetto al rumore e quindi che y_k rifletta la curvatura vera e non solo il rumore. Se α_k non produce un y_k affidabile, l'algoritmo allunga il passo (aumenta β_k) fino a raccogliere una differenza di gradienti significativa.

- **Line search a due fasi tollerante al rumore:** la procedura proposta è una line search a due fasi, nella prima fase si cerca un α_k che soddisfi contemporaneamente le condizioni di Wolfe forti (2, 3) e la noise control condition (5). In questo caso si pone $\beta_k = \alpha_k$. Se non si riesce a trovare tale α_k , si entra nella seconda fase, in cui si cerca un α_k che soddisfi la condizione di Armijo e un $\beta_k \geq \alpha_k$ che soddisfi solo la noise control condition. In questo modo, l'algoritmo garantisce che l'aggiornamento della matrice Hessiana sia basato su informazioni affidabili, anche in presenza di rumore.
- **Aggiornamento della matrice β_k :** una volta determinati α_k e β_k , l'aggiornamento della matrice Hessiana approssimata B_k viene eseguito con la stessa formula dell'algoritmo BFGS (4), ma utilizzando

$$s_k = \beta_k d_k, \quad y_k = \nabla f(x_k + \beta_k d_k) - \nabla f(x_k).$$

Questo assicura che l'aggiornamento sia basato su una differenza di gradienti che supera il rumore, migliorando la stabilità e l'affidabilità dell'algoritmo in contesti rumorosi.

Il contributo principale del paper non è cambiare la struttura fondamentale dell'algoritmo BFGS, ma rendere robusto l'algoritmo esistente in presenza di rumore, introducendo meccanismi per garantire che le informazioni utilizzate per aggiornare la matrice Hessiana siano affidabili. Queste modifiche permettono a BFGS tollerante al rumore di conservare i vantaggi dei metodi Quasi-Newton, anche quando le valutazioni sono affette da errori.

3 Esperimenti

In questa sezione vengono presentati gli esperimenti volti a valutare le prestazioni dell'algoritmo BFGS tollerante al rumore, confrontandolo con BFGS classico (sia nella versione implementata personalmente sia nella versione fornita dalla libreria SciPy) e con il metodo di discesa del gradiente implementato personalmente. Gli esperimenti sono stati eseguiti su un benchmark di sei problemi presi dalla libreria PyCUTEst. Per ciascun metodo è stato registrato: il numero di iterazioni necessarie per la convergenza (definita come norma del gradiente inferiore a un valore tolleranza), l'andamento dei valori della funzione obiettivo e del gradiente ad ogni iterazione, e il tempo di esecuzione totale. Per gli algoritmi progettati per problemi non rumorosi abbiamo valutato le prestazioni sia su funzioni prive di rumore sia su funzioni rumorose, in modo da evidenziare l'effetto del rumore sugli algoritmi classici e successivamente verificare l'efficacia della versione BFGS tollerante al rumore. Nei paragrafi successivi sono riportati i dettagli i risultati ottenuti, presentati sia in forma tabellare che grafica.

Prima di passare ai risultati, viene fornita una breve panoramica dei dettagli tecnici degli esperimenti:

- **Ricerca di linea:** per il metodo di discesa del gradiente (GD) è stata implementata una ricerca di linea che utilizza la sola *condizione di Armijo*. Per BFGS classico è stata implementata una ricerca di linea che soddisfa le *condizioni di Wolfe forti*. Per BFGS tollerante al rumore la ricerca di linea è basata sulle stesse Condizioni di Wolfe forti, con l'aggiunta della *condizione di controllo del rumore* descritta nella Sezione 2.
- **Aggiunta di rumore:** ad ogni valutazione della funzione obiettivo e del gradiente è stato aggiunto rumore gaussiano $\mathcal{N}(0, \sigma^2)$, dove σ è il livello di rumore scelto per l'esperimento. Alla valutazione scalare della funzione obiettivo si somma un termine scalare di rumore; al gradiente si aggiunge invece un vettore di rumore, perturbando ciascuna componente.
- **Tolleranza:** una volta fissati i livelli di rumore (in particolare quello sul gradiente), la tolleranza per la condizione di arresto è stata determinata in modo dinamico affinché risultasse sempre maggiore del rumore sul gradiente. In questo modo si evita che il rumore impedisca la terminazione degli algoritmi. Inoltre, per garantire la coerenza nel confronto tra metodi, la stessa regola è stata applicata anche alle istanze prive di rumore: la tolleranza è stata calcolata come se fosse presente rumore, mantenendo omogenee le condizioni di arresto tra gli esperimenti.

3.1 Numero di Iterazioni

Per ogni problema scelto dal benchmark, la Tabella 1 riporta il numero medio di iterazioni necessarie per la convergenza dei diversi metodi, sia in assenza che in presenza di rumore di piccola entità (livello di rumore 10^{-8}). La tabella include anche il numero di esecuzioni che hanno effettivamente raggiunto la convergenza,

Tabella 1: Numero medio di iterazioni impiegate dai diversi metodi, sia in assenza che in presenza di rumore di piccola entità (10^{-8}), per ogni problema del benchmark. La tabella riporta anche il numero di esecuzioni che hanno effettivamente raggiunto la convergenza, per ciascuna configurazione sono state eseguite 50 prove.

Problema	GD (no rumore)		GD (con rumore)		BFGS (no rumore)		BFGS (con rumore)		BFGS Tollerante (con rumore)		SciPy BFGS (no rumore)		SciPy BFGS (con rumore)	
	media	convergeti	media	convergeti	media	convergeti	media	convergeti	media	convergeti	media	convergeti	media	convergeti
ALLINITU	312.000	50	4916.040	31	33.000	50	64.840	50	19.520	50	12.000	50	12.800	1
BOX	78.000	50	10000.000	0	28.000	50	39.920	48	36.440	50	5.000	0	5.900	0
BOXPOWER	10000.000	0	10000.000	0	80.000	50	1782.286	45	373.420	49	44.000	0	10.460	0
BRKMCC	218.000	50	10000.000	0	32.000	50	35.820	44	11.060	50	5.000	50	5.060	7
BROYDN7D	10000.000	0	10000.000	0	122.000	50	171.880	49	194.660	50	77.000	0	71.200	0
DENSCINA	51.000	50	9688.100	2	30.000	50	34.360	50	13.060	50	11.000	50	9.860	0

evidenziando eventuali difficoltà incontrate dai metodi in condizioni rumorose. Il numero di esecuzioni per ogni configurazione è stato fissato a 50.

3.2 Andamento Funzione Obiettivo e Norme del Gradiente

3.3 Tempi di Esecuzione

Tabella 2: Numero medio di iterazioni impiegate dai diversi metodi, sia in assenza che in presenza di rumore di grande entità (10^{-5}), per ogni problema del benchmark. La tabella riporta anche il numero di esecuzioni che hanno effettivamente raggiunto la convergenza, per ciascuna configurazione sono state eseguite 50 prove.

Problema	GD (no rumore)		GD (con rumore)		BFGS (no rumore)		BFGS (con rumore)		BFGS Tollerante (con rumore)		SciPy BFGS (no rumore)		SciPy BFGS (con rumore)	
	media	convergeti	media	convergeti	media	convergeti	media	convergeti	media	convergeti	media	convergeti	media	convergeti
ALLINITU	226.000	50	427.960	31	22.000	50	26.400	50	15.940	50	10.000	50	11.620	5
BOX	45.000	50	10000.000	0	19.000	50	26.120	50	34.920	50	5.000	50	5.240	0
BOXPOWER	10000.000	0	10000.000	0	49.000	50	2498.755	39	666.380	47	9.000	50	9.760	0
BRKMCC	140.000	50	9719.800	1	21.000	50	25.880	48	12.660	50	4.000	50	3.820	9
BROYDN7D	139.000	50	10000.000	0	104.000	50	137.000	50	179.940	50	71.000	0	68.000	0
DENSCHINA	31.000	50	2982.200	40	20.000	50	24.480	50	11.280	50	9.000	50	8.200	4

Riferimenti bibliografici

- [1] Hao-Jun M Shi, Yuchen Xie, Richard Byrd, and Jorge Nocedal. A noise-tolerant quasi-newton algorithm for unconstrained optimization. *SIAM Journal on Optimization*, 32(1):29–55, 2022.